Dataset escolhido: fotos de gatos e cães

7.360

imagens únicas (7.390 baixadas − 30 duplicatas exatas)

2 classes

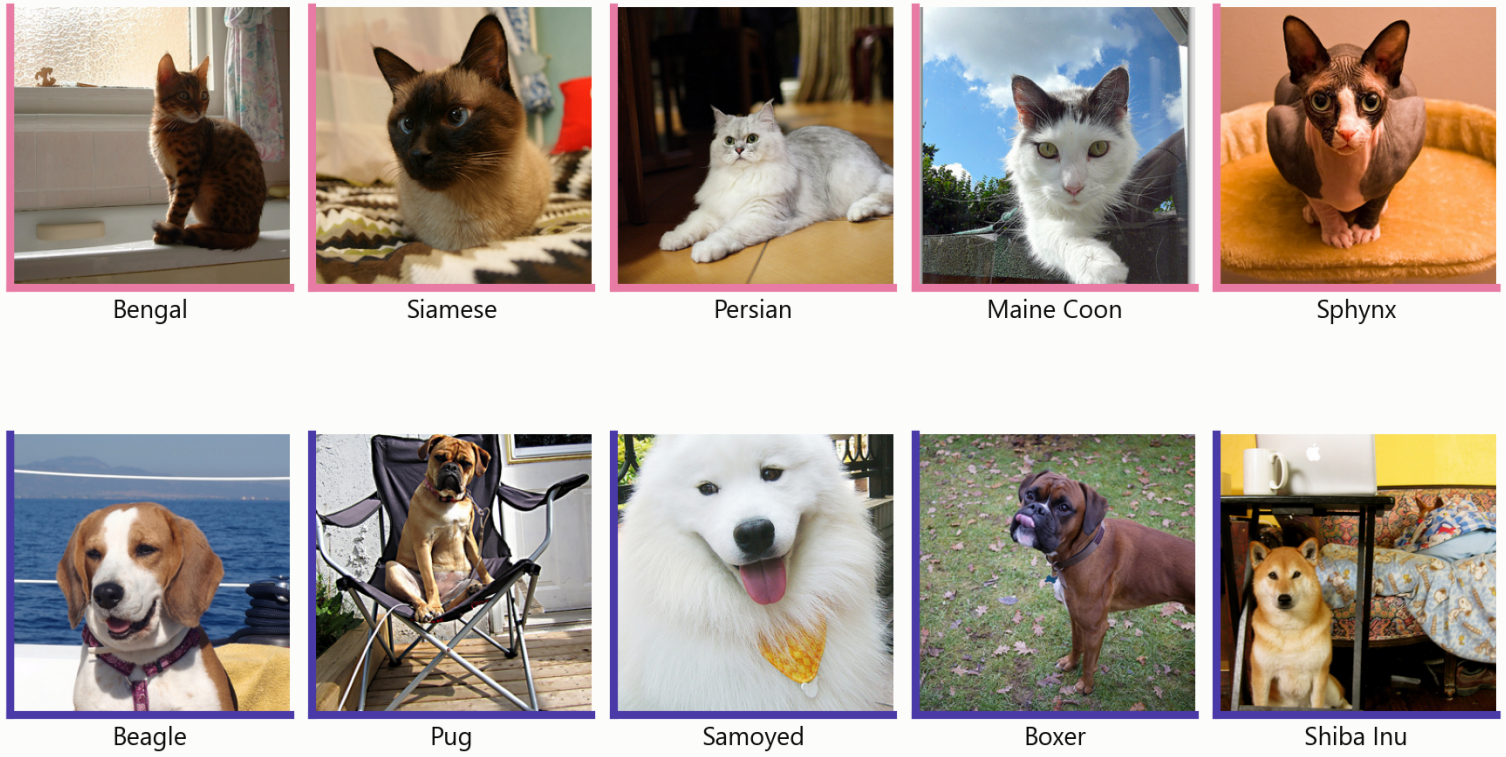
Gato (2.380) e Cão (4.980) · problema binário

37 raças

12 de gato e 25 de cão, com 184–200 imagens cada

POR QUE ESTA BASE

- **Volume:** 7.360 imagens bastam para dividir em Train/Val/Test e ainda medir cada conjunto.
- **Variedade real:** fotos com poses, fundos, iluminação e resoluções muito diferentes.
- **Desbalanceamento genuíno** gato × cão para discutir (não foi criado artificialmente).
- **Rótulo gratuito e confiável**, derivado do nome do arquivo.



Exemplos do conjunto de treino (miniaturas recortadas ao centro só para exibição). Contorno rosa = gato, violeta = cão.

FONTE E RÓTULOS

Kaggle · **yashdogra/cats-and-dogs** (mesma estrutura de nomes do Oxford-IIIT Pet). O nome do arquivo dá o rótulo: **Abyssinian_1.jpg → gato / Abyssinian**; **beagle_42.jpg → cão / beagle** (raça de gato começa com maiúscula).

DIVISÃO DOS DADOS

Train / Validation / Test = 70 / 15 / 15, estratificado



CONJUNTO	IMAGENS	%	GATOS	CÃES	PARA QUÊ
Train	5.152	70,0%	1.666	3.486	Ajusta os pesos da CNN.
Validation	1.104	15,0%	358	746	Escolhe hiperparâmetros, early stopping.
Test	1.104	15,0%	356	748	Nota final. Usado uma única vez, no fim.

Total: 7.360 imagens · proporção gato/cão em cada conjunto: 32,3% / 32,4% / 32,2% gatos.

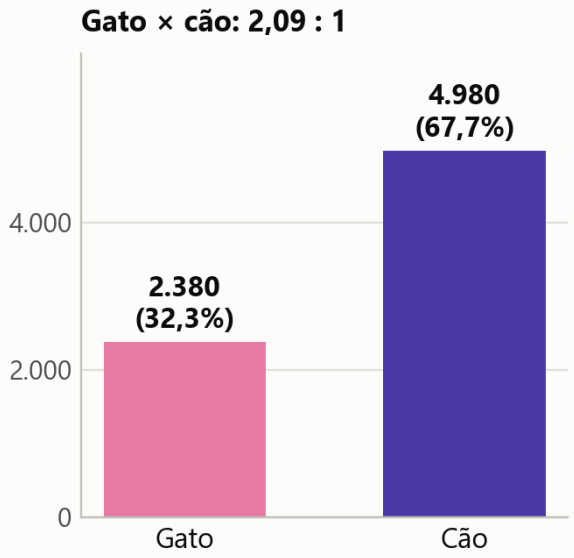
POR QUE ESTA DIVISÃO

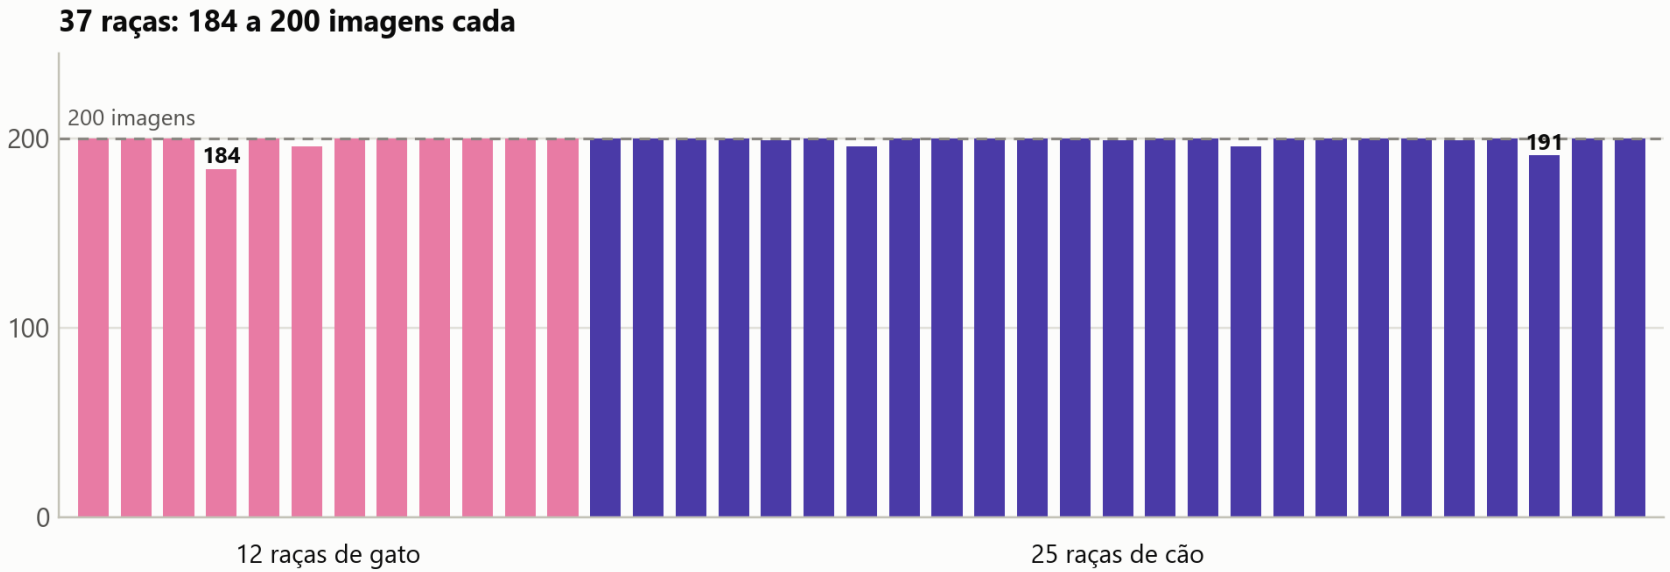
- **70% treino:** cerca de 5 mil imagens para a CNN aprender features de pelagem, focinho e orelhas.
- **15% + 15%:** ~1.100 imagens em Val e Test dão margem de erro de ≈ ±1,8 p.p. (IC 95%) para acurácia de ~90% (±3 p.p. no pior caso).
- **Estratificada por raça** (seed 42): cada raça é dividida 70/15/15, então espécie e raça ficam proporcionais nos 3 conjuntos.
- **Sem vazamento:** duplicatas exatas removidas antes do split.

COMO FOI FEITO (REPRODUTÍVEL)

- Hash MD5 dos 7.390 arquivos → 29 grupos idênticos; mantém 1 de cada (nenhum grupo com raças diferentes).
- Divisão em dois passos com **train_test_split(stratify=raça, random_state=42)**: 70% / 30%, e os 30% em 50/50.
- Cópia para **dataset/{train,val,test}/{gato,cao}/** (pronto para ImageFolder / image_dataset_from_directory) e manifesto **splits.csv**.

Balanceado por raça, desbalanceado entre gato e cão





O DATASET ESTÁ BALANCEADO?

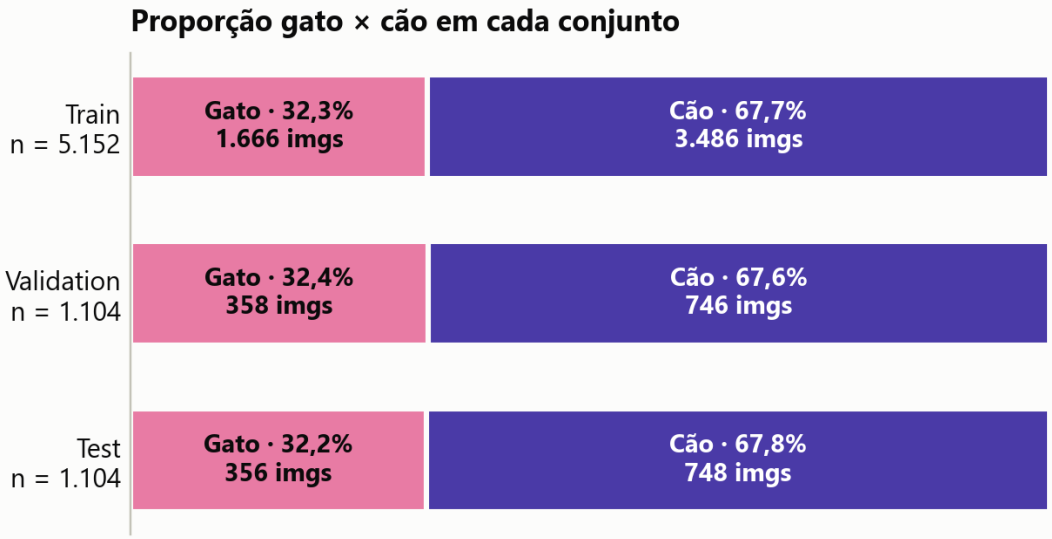
Por raça (37 classes): sim. 184 a 200 imagens por raça (razão 1,09 : 1).

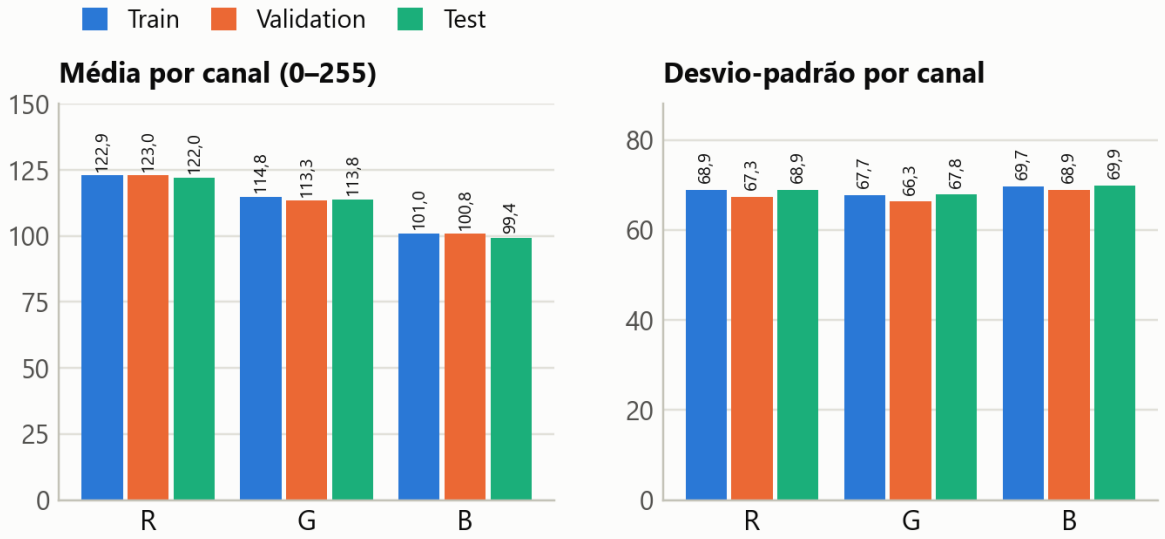
Por espécie (gato × cão): não. 2.380 × 4.980 = **2,09 : 1**. Um modelo que responde sempre "cão" já acerta 67,7% sem aprender nada.

COMO VAMOS TRATAR

- **Pesos de classe na loss** ($n / 2 \cdot n_{classe}$, calculado no Train): gato ≈ 1,55 · cão ≈ 0,74.
- **Métricas que enxergam a minoria:** F1 e recall por classe + matriz de confusão, em vez de só acurácia.
- **Mesma proporção em Val e Test** (split estratificado): métricas comparáveis entre os conjuntos.
- **Sem undersampling:** descartaria ~2.600 fotos de cães. Augmentation só no Train.

Classes e estatísticas de pixel são comparáveis





p = 0,996

teste χ^2: proporção gato/cão × conjunto. Sem diferença detectável (raça: p = 1,0).

≤ 1,66 de 255

maior diferença entre as médias RGB de dois conjuntos (0,65% da escala).

D ≤ 0,030

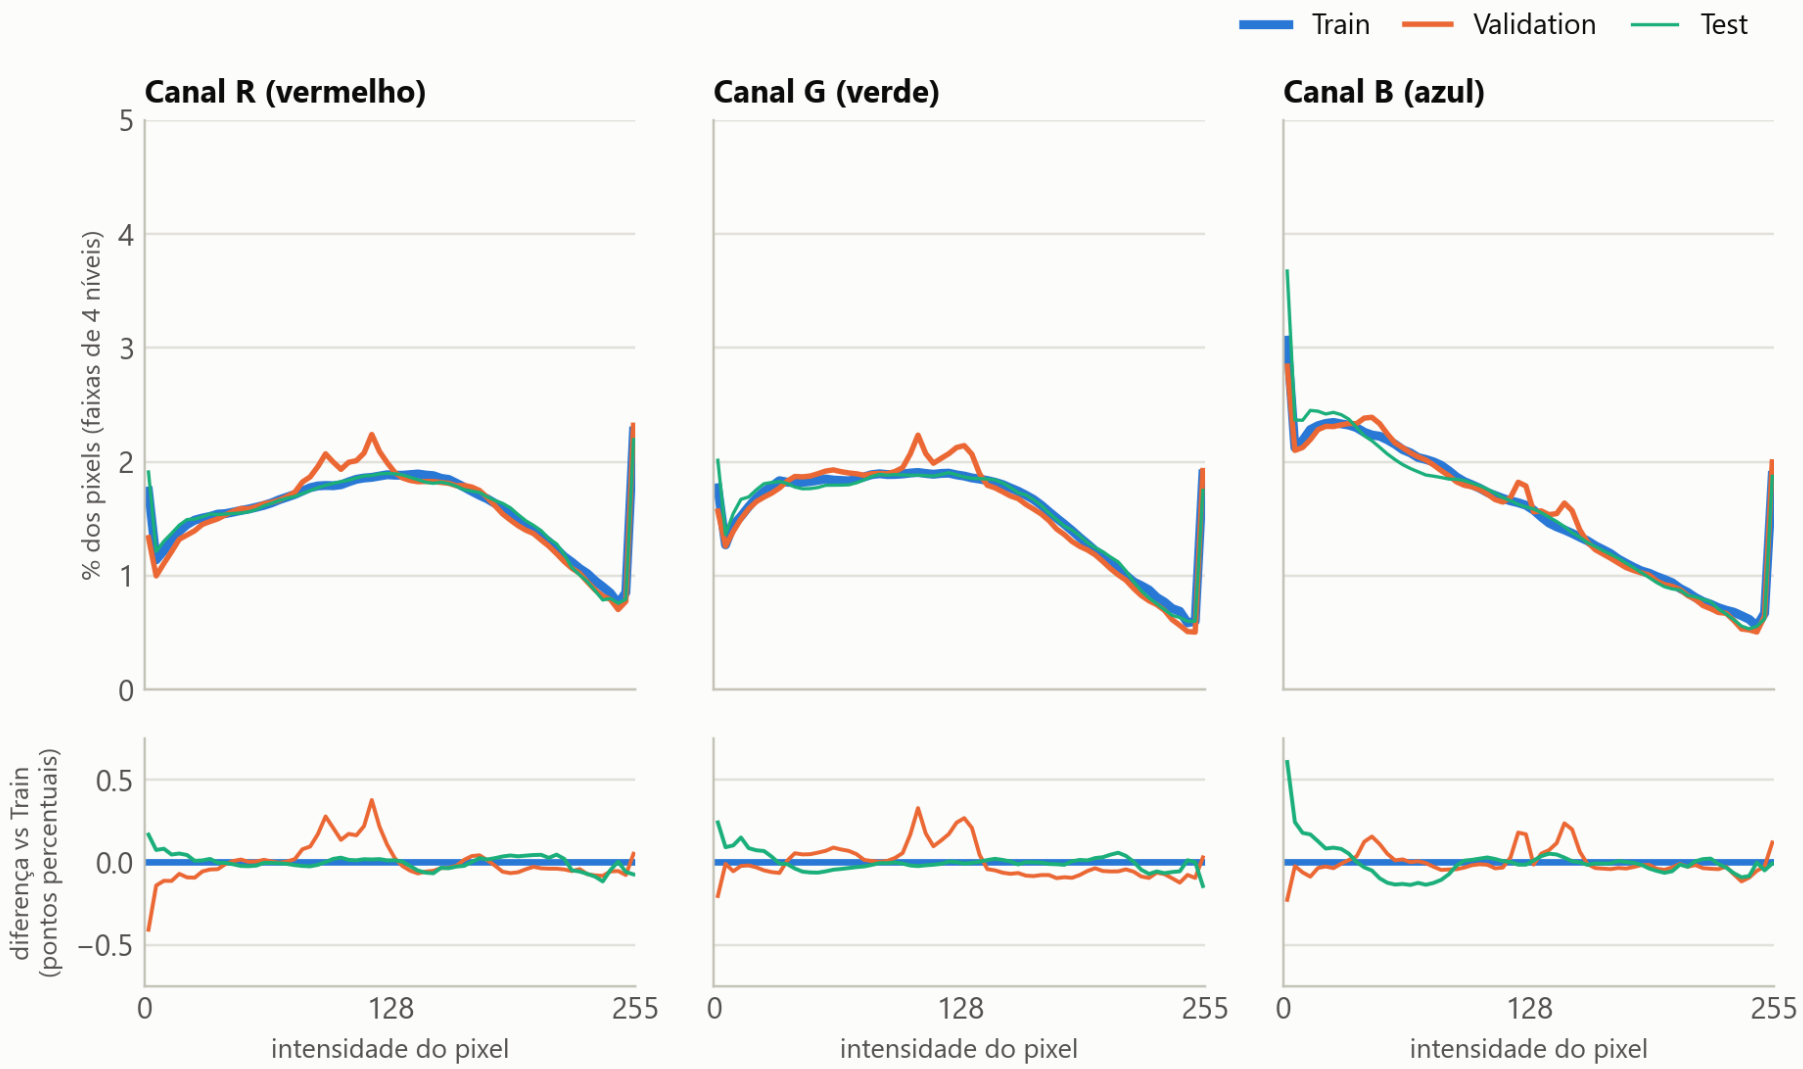
KS 2 amostras no brilho e no contraste por imagem (p ≥ 0,46). D é a distância máxima entre as curvas acumuladas.

≤ 2,0 níveis

distância de Wasserstein entre os histogramas RGB (em níveis de intensidade, de 0 a 255).

Leitura: o objetivo não é deixar os conjuntos idênticos, e sim garantir que nenhum tenha um "visual" muito diferente. As pequenas diferenças (≈ 1 nível de 255) são o ruído esperado de amostrar ~1.100 imagens; nada aponta para viés de seleção.

Histogramas de intensidade e canais RGB



O QUE A FIGURA MOSTRA

- As curvas de Train, Validation e Test **quase se sobrepõem** nos 3 canais.
- Embaixo, a diferença vs Train fica em **até ≈ 0,6 ponto percentual** por faixa de 4 níveis, concentrada nas pontas (0 e 255) e num pico de Validation perto de 128, compatível com ruído de amostragem.

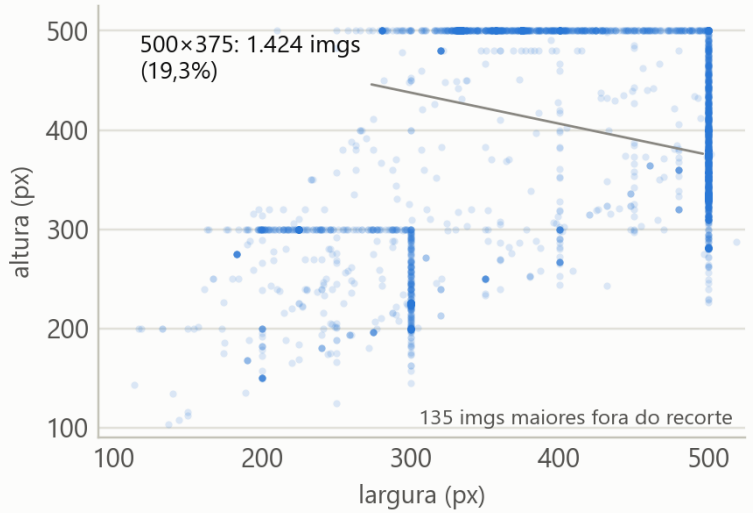
NÚMEROS QUE SUSTENTAM

- **Intervalo dos pixels:** 0 a 255 (uint8) nos 3 conjuntos: min = 0, max = 255.
- **Brilho médio por imagem:** 115,7 · 115,2 · 114,5 (Train · Val · Test), σ ≈ 30.
- **Perfil comum:** B mais baixo que R e G (média B ≈ 101, R ≈ 123): predominam tons quentes.

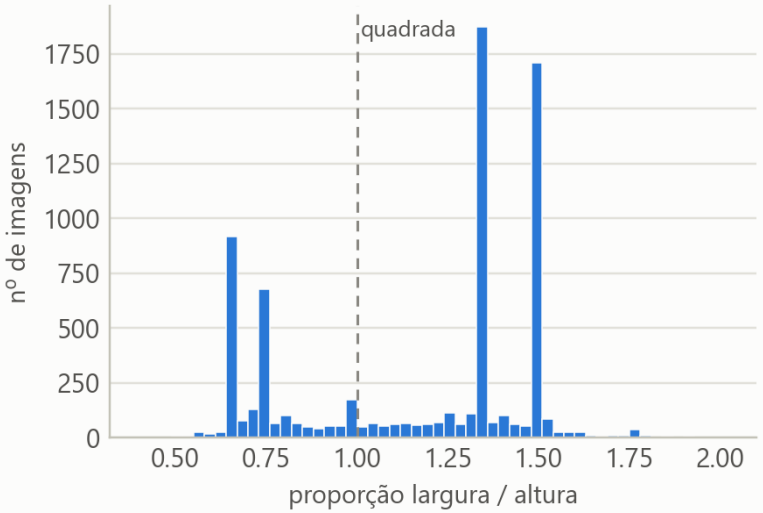
Conclusão: Val e Test representam o mesmo tipo de imagem do Train.

Resoluções muito variadas, sempre 3 canais

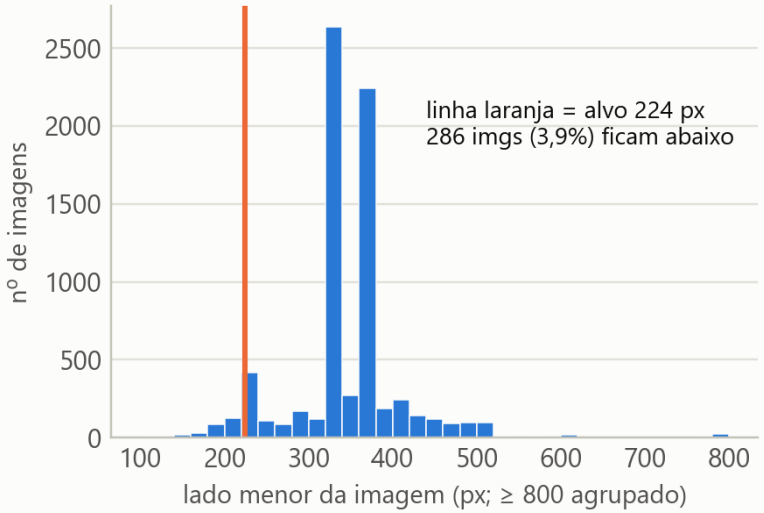
Largura × altura de cada imagem



Proporção: mediana 1,33 (4:3)



Lado menor vs. alvo de entrada



1.022

resoluções distintas. Mais comuns: 500×375 (19,3%) e 500×333 (14,5%).

114–3.264 px

largura (mediana 500). Altura: 103–2.606 px (mediana 375).

3 canais

todas as imagens saem em RGB. 12 eram GIF/PNG/tons de cinza/RGBA disfarçados de .jpg e foram convertidos.

0 – 255

intervalo dos pixels (uint8) nos 3 conjuntos; ainda sem escala. Proporção típica 4:3 ou 3:4 (só 4,3% ≈ quadradas).

O QUE ISSO IMPLICA PARA A CNN

- **Entrada de tamanho fixo:** para formar batches e alimentar as camadas densas finais, todas as imagens precisam ter o mesmo tamanho.
- **Proporção quase nunca quadrada** (95,7% das imagens): distorcer, cortar ou preencher têm custos diferentes. A escolha está justificada no próximo slide.
- **Extremos:** imagens de até 3.264 px serão reduzidas e 286 pequenas serão ampliadas, o que altera um pouco a nitidez.

Padronização para a CNN: 224 × 224 × 3

Original	Resize direto (distorce a proporção)	**Resize + center crop (escolhido)**	Resize + padding (barras pretas)
 500×375 px	 ×1,33 de distorção	 perde 25% da área	 25% da entrada vazia
 375×500 px	 ×1,33 de distorção	 perde 25% da área	 25% da entrada vazia

1. **Resize:** lado menor → 224 px (bicúbico), mantendo a proporção
2. **Center crop:** recorta 224 × 224 no centro
3. **Normalização:** x / 255 → (x − μ) / σ por canal, com μ e σ do Train

→ entrada da CNN: 224 × 224 × 3 (float32)

POR QUE ESSA ESTRATÉGIA

- **Resize com proporção fixa:** esticar direto distorce a imagem (×1,33 na mediana) e deforma focinho e orelhas.
- **Crop em vez de padding:** ambos gastam a mesma fração da entrada (média 26,7%). O crop descarta só bordas; o padding preenche com pixels pretos sem informação. Premissa: o animal fica perto do centro (vale nos exemplos vistos).
- **224 px:** tamanho padrão de backbones pré-treinados. Só 286 imagens (3,9%) têm lado menor < 224 e serão ampliadas.
- **Val/Test:** sempre o mesmo pipeline determinístico. Augmentation (flip, RandomResizedCrop) só no Train.

NORMALIZAÇÃO ESCOLHIDA

Só do Train (sem vazamento): μ = (0,487; 0,452; 0,399) e σ = (0,265; 0,260; 0,267). Aplicada em Val/Test, dá |μ| ≤ 0,020 e σ entre 0,994 e 1,006. Com backbone pré-treinado, trocar pelas constantes do ImageNet (μ = 0,485; 0,456; 0,406 · σ = 0,229; 0,224; 0,225).

ANÁLISE FINAL

O dataset está pronto para treinar uma CNN?

O DATASET ESTÁ BALANCEADO?

PARCIALMENTE

- **Raças:** sim (184–200 por raça).
- **Gato × cão:** não (2,09 : 1; 32,3% × 67,7%).
- **Tratamento:** pesos de classe (gato ≈ 1,55, cão ≈ 0,74), F1/recall por classe, sem undersampling.

TRAIN, VAL E TEST SÃO SEMELHANTES?

SIM

- Proporção de classes idêntica (χ^2 p = 0,996).
- Médias RGB a ≤ 1,66 de 255; KS D ≤ 0,030; histogramas quase sobrepostos.
- Pequenas diferenças são ruído de amostragem, não viés.

AS IMAGENS ESTÃO PADRONIZADAS?

SIM

- Todas em RGB, 224 × 224 × 3, via resize (proporção fixa) + center crop.
- Normalização com μ = (0,487, 0,452, 0,399) e σ = (0,265, 0,260, 0,267), só do Train.
- Após normalizar, Val/Test ficam com |μ| ≤ 0,020 e σ entre 0,994 e 1,006.

ESTÁ PRONTO PARA O TREINAMENTO?

SIM, COM 3 CUIDADOS

- Aplicar pesos de classe e acompanhar F1/recall, não só acurácia.
- Usar o Test uma única vez, no final.
- Só duplicatas exatas foram removidas: quase-duplicatas podem existir. E 286 imagens pequenas serão ampliadas.