Dataset escolhido: DeepWeeds, espécies de plantas

17.509

imagens de campo (0 duplicatas exatas; 0 arquivos ausentes)

9 classes

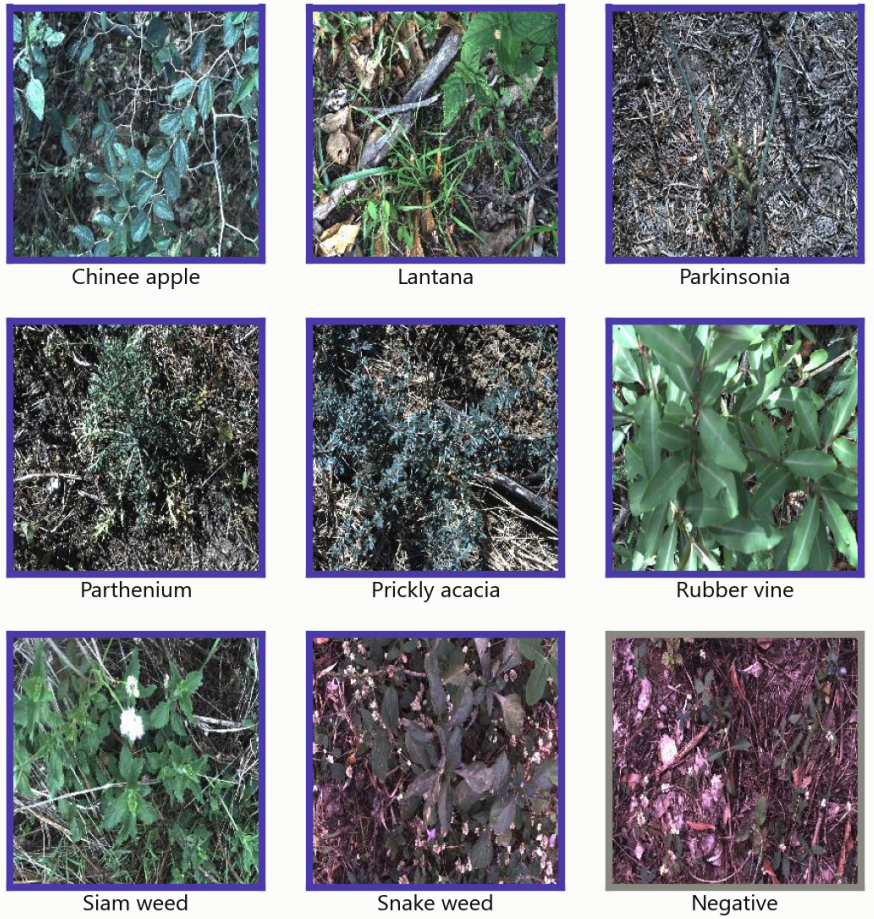
8 espécies-alvo + “Negative” (vegetação sem espécie-alvo)

256 × 256 RGB

todas as imagens, mesmo tamanho e 3 canais

POR QUE ESTA BASE

- **Foco em espécies:** ~1.000 fotos de cada uma das 8 espécies (1.009 a 1.125).
- **Vegetação real de campo:** luz, fundo e ângulo variados (101 sessões de captura, 60 datas).
- **Desbalanceamento genuíno:** “Negative” é 52% das imagens.
- **Licença CC BY 4.0** e download público.
- **Ligação com o projeto:** reconhecer espécies de vegetação é base para monitorar faixas de rodovia (Motiva); aqui, vegetação australiana como ponto de partida.



Uma imagem de cada classe, sorteada do Train. Contorno violeta = espécie-alvo; cinza = Negative.

FONTE E RÓTULOS

GitHub · **AlexOlsen/DeepWeeds** (Olsen et al., Scientific Reports, 2019). Fotos tiradas em 8 locais do norte da Austrália.

labels.csv traz Filename, Label, Species. A data, a hora e a câmera vêm do nome do arquivo (AAAAMMDD-HHMMSS-ID).

Espécies: Chinee apple, Lantana, Parkinsonia, Parthenium, Prickly acacia, Rubber vine, Siam weed, Snake weed.

INTEGRANTES

Lucas Ferrari Lima · RM 563119
Carlos Eduardo Pires Cervelli · RM 563462
Felipe Krzyzanovski dos Santos Menezes · RM 564878
Leonardo Lopes Oliveira · RM 565437
Arthur de Souza Matos Dias · RM 566068
Guilherme Carreri Giampietro · RM 565676
Mateus Patrício Pereira · RM 564695

DIVISÃO DOS DADOS

Train / Validation / Test = 70 / 15 / 15, estratificado



CONJUNTO	IMAGENS	%	8 ESPÉCIES	NEGATIVE	PARA QUÊ
Train	12.256	70,0%	5.882	6.374	Ajusta os pesos da CNN.
Validation	2.626	15,0%	1.260	1.366	Hiperparâmetros e early stopping.
Test	2.627	15,0%	1.261	1.366	Nota final, usado uma vez.

Total: 17.509 imagens · a proporção de cada classe é a mesma nos 3 conjuntos (slide 4).

POR QUE ESTA DIVISÃO

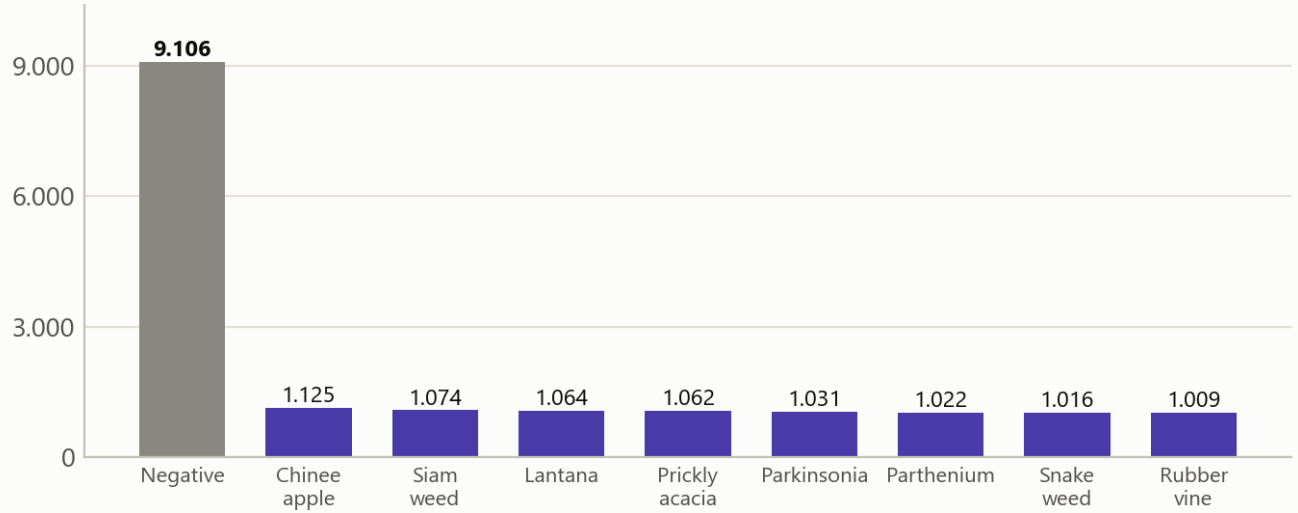
- **70% treino:** ~12.256 imagens para 9 classes: dados de sobra para a CNN aprender folha, textura e porte.
- **15% + 15%:** ~2.626 imagens em Val e em Test dão margem de ≈ ±1,1 p.p. (IC 95%) para acurácia de ~90% (±1,9 p.p. no pior caso).
- **Estratificada por classe** (seed 42): até a menor espécie (Rubber vine, 1.009) fica com 706 / 152 / 151 imagens.

COMO FOI FEITO (REPRODUTÍVEL)

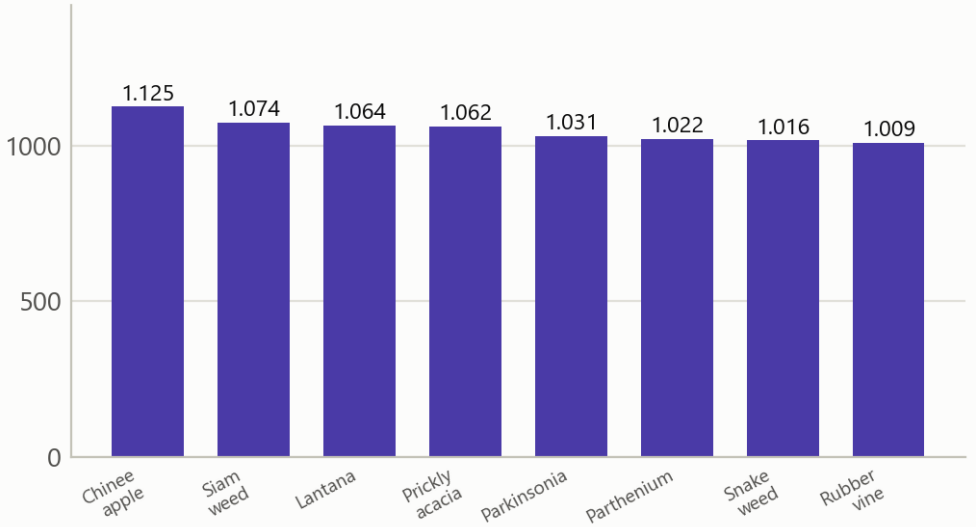
- Conferência: 17.509 linhas no labels.csv × 17.509 arquivos; hash MD5 sem duplicatas exatas; todas as imagens abrem como RGB.
- Divisão em dois passos com **train_test_split(stratify=classe, random_state=42)**: 70% / 30%, e os 30% em 50/50.
- Cópia para **dataset/{train,val,test}/<Classe>/** (pronto para ImageFolder) e manifesto **splits.csv**.

Espécies balanceadas, mas “Negative” domina

9 classes: Negative = 52,0% (8,7× uma espécie)



Só as 8 espécies: 1.009 a 1.125 (1,11 : 1)



O DATASET ESTÁ BALANCEADO?

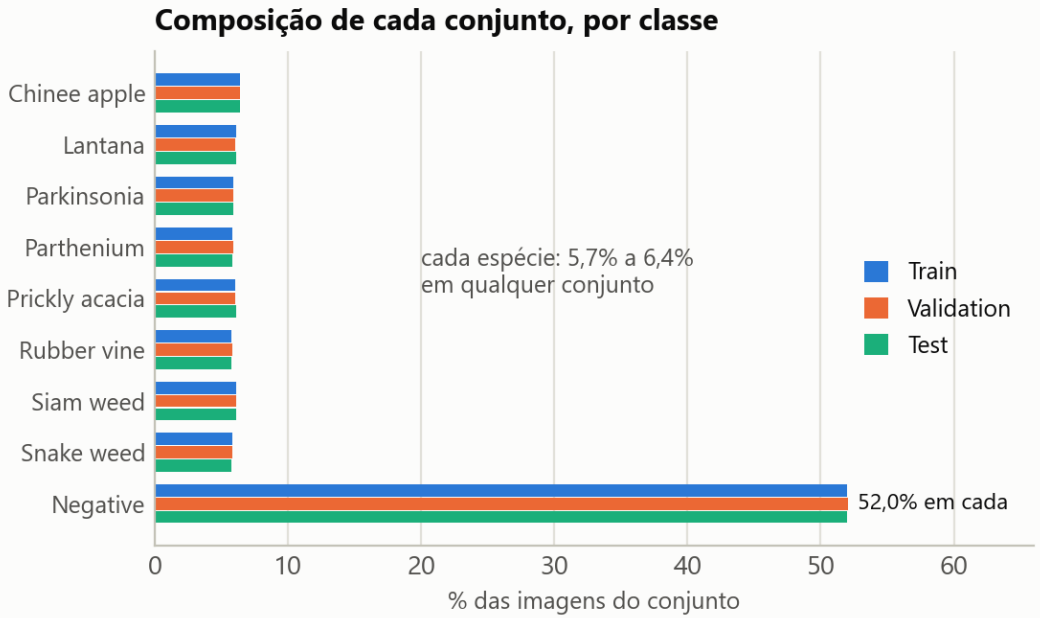
Só as 8 espécies: sim. 1.009 a 1.125 imagens por espécie (razão 1,11 : 1).

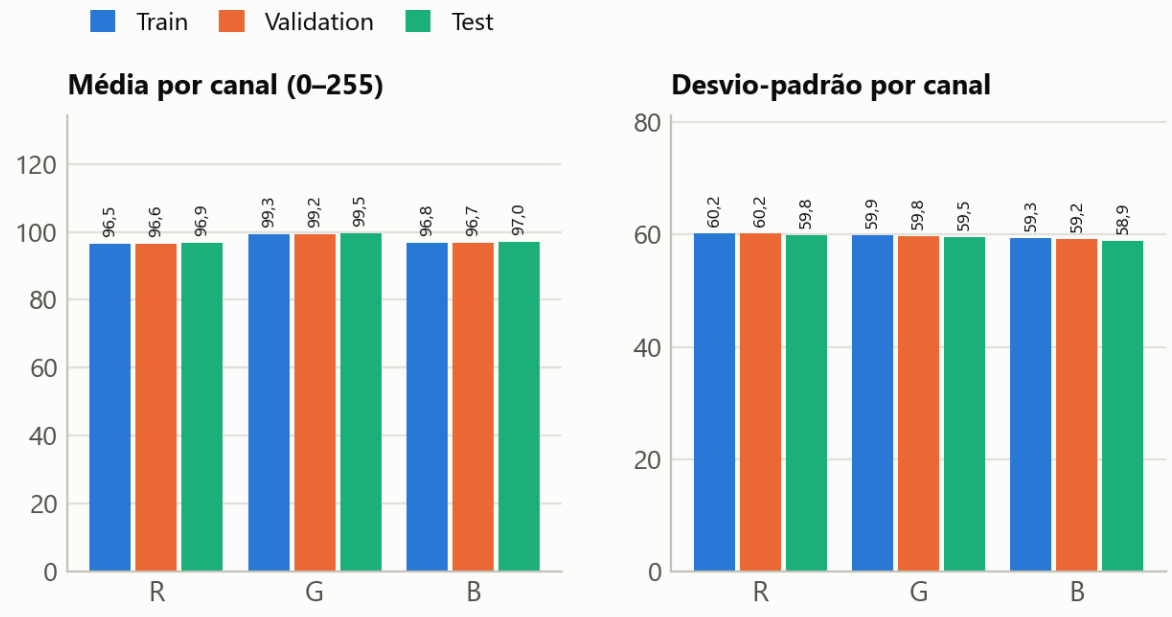
Com “Negative”: não. 9.106 imagens = **52,0%** do total, 8,7× uma espécie média. Responder sempre “Negative” já acerta 52,0% sem aprender nada.

COMO VAMOS TRATAR

- **Pesos de classe na loss** ($n / k \cdot n_{classe}$, calculado no Train): Negative ≈ 0,21; espécies ≈ 1,73 a 1,93.
- **Métricas por classe:** recall e F1 de cada espécie, F1 macro e matriz de confusão, em vez de só acurácia.
- **Mesma proporção em Val e Test** (split estratificado): métricas comparáveis.
- **Sem undersampling agressivo:** descartaria milhares de fotos de vegetação real, que ensinam o que não é espécie-alvo. Augmentation só no Train.
- **Se os pesos não bastarem:** oversampling das espécies ou focal loss (a testar no treino).

Classes e estatísticas de pixel são comparáveis





p ≈ 1,00

teste χ^2: composição de classes × conjunto. Nenhuma diferença detectável.

≤ 0,4 de 255

maior diferença entre as médias RGB de dois conjuntos (0,16% da escala).

D ≤ 0,028

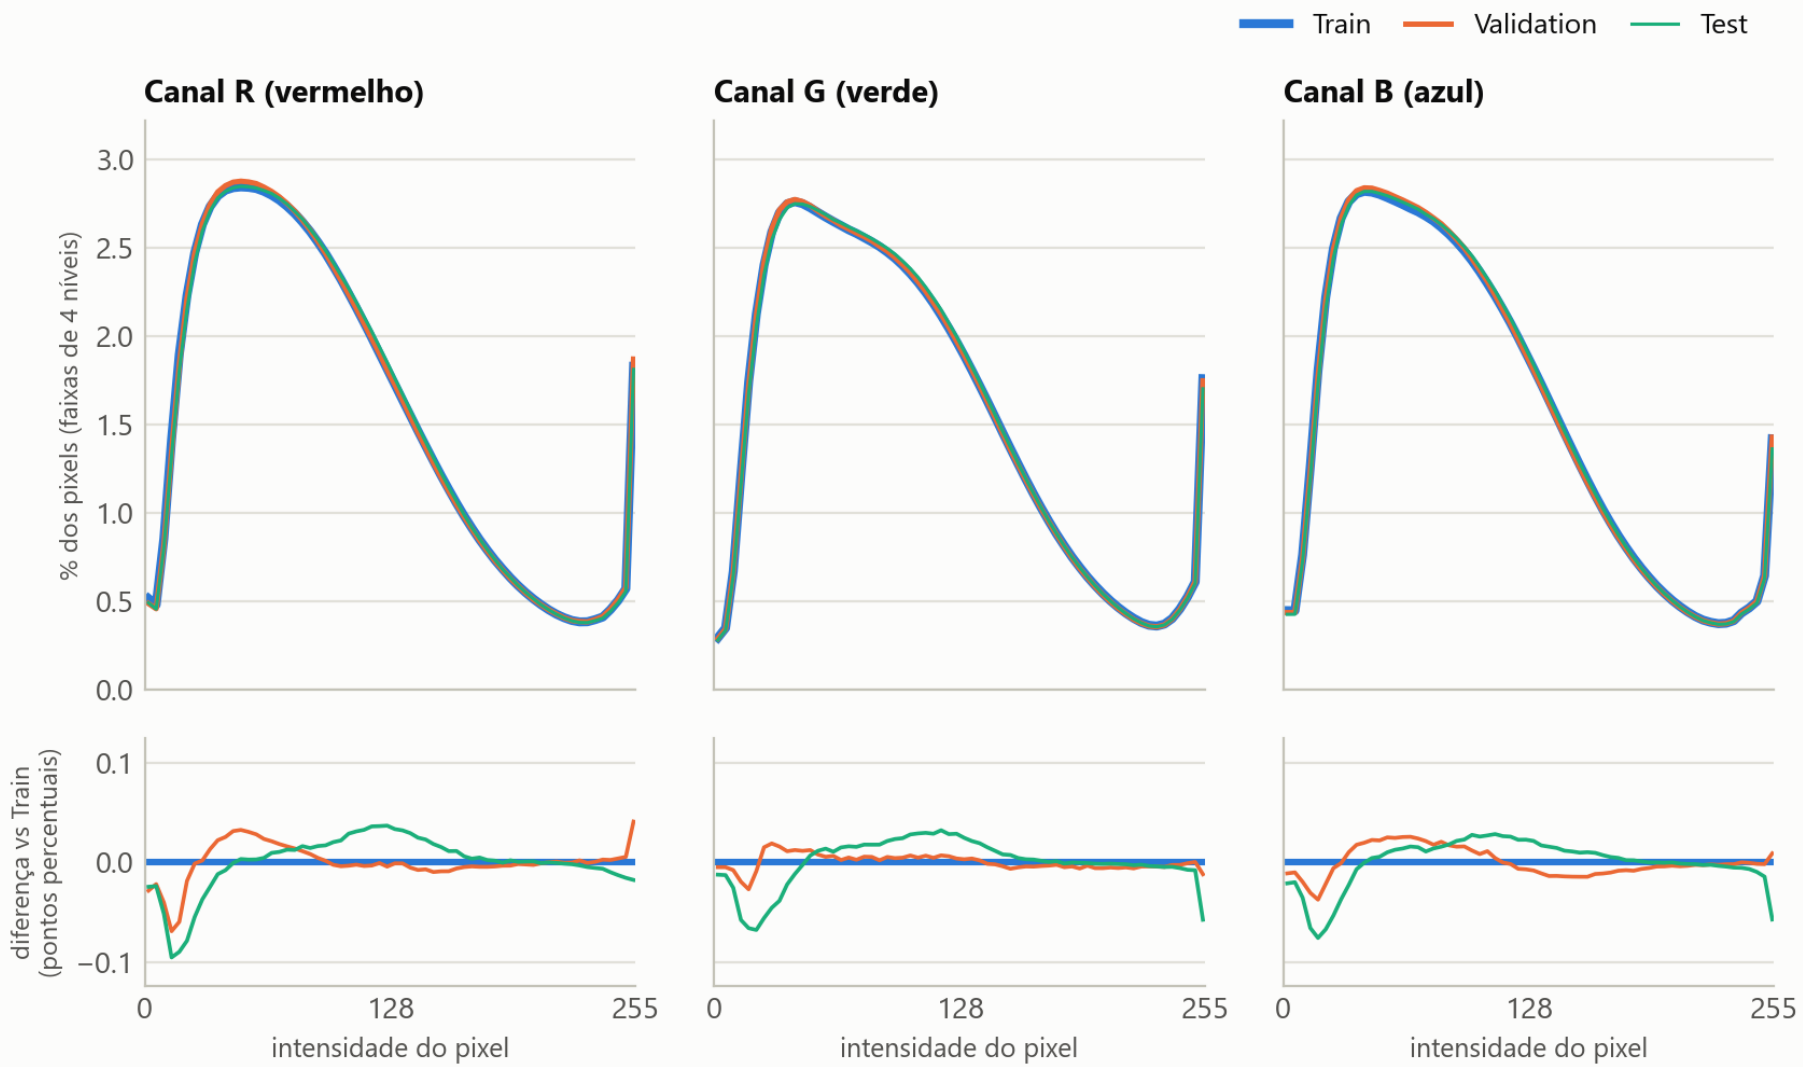
KS 2 amostras no brilho e no contraste por imagem (p ≥ 0,28). D = distância máxima entre as curvas acumuladas.

≤ 0,6 nível

distância de Wasserstein entre os histogramas RGB (em níveis de intensidade, de 0 a 255).

Leitura: o objetivo não é deixar os conjuntos idênticos, e sim garantir que nenhum tenha um "visual" muito diferente. As diferenças são de ~0,4 nível em 255, ruído esperado de amostrar ~2.626 imagens. Ressalva: como o split é aleatório, as sessões de captura são compartilhadas entre os conjuntos (slide 6).

Histogramas de intensidade e canais RGB



O QUE A FIGURA MOSTRA

- As curvas de Train, Validation e Test **praticamente coincidem** nos 3 canais.
- Embaixo, a diferença vs Train **não passa de ≈ 0,1 ponto percentual** por faixa de 4 níveis, sem padrão sistemático.

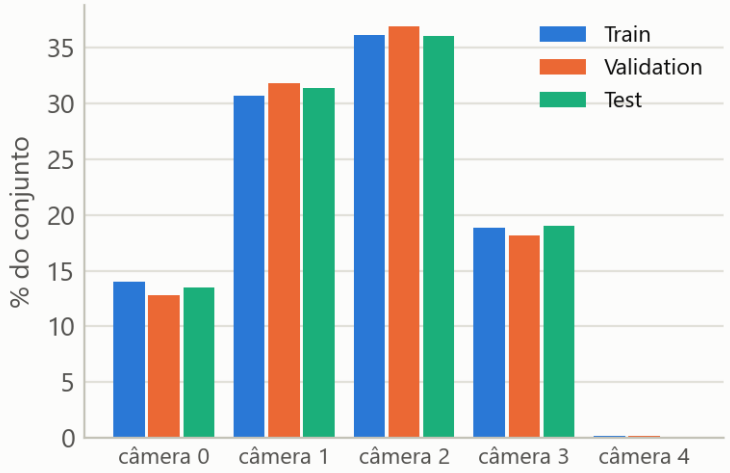
NÚMEROS QUE SUSTENTAM

- **Intervalo dos pixels:** 0 a 255 (uint8) nos 3 conjuntos.
- **Brilho médio por imagem:** 98,2 · 98,1 · 98,4 (Train · Val · Test).
- **Perfil comum:** imagens escuras (média ≈ 96–99 de 255) e um pico em 255 (pixels estourados).

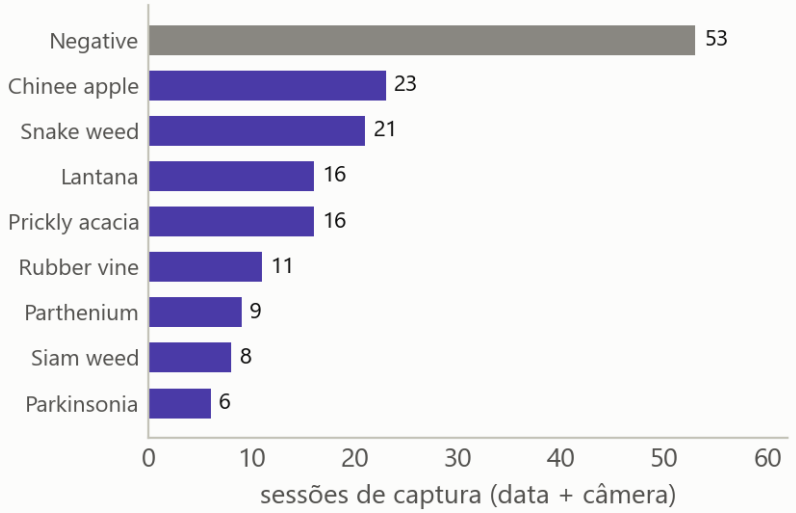
Conclusão: Val e Test têm o mesmo perfil de cor do Train.

Tamanho uniforme; o risco está na sessão de captura

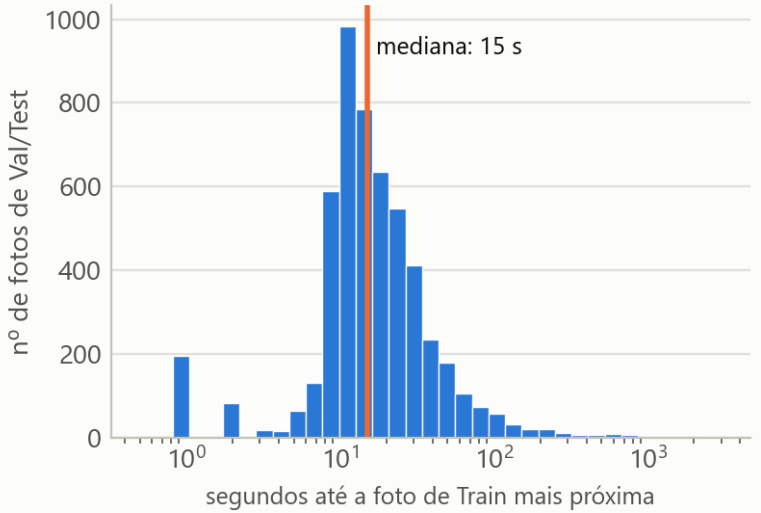
Câmeras: mesma mistura nos 3 conjuntos (p = 0,66)



Sessões por classe (total: 101)



99,8% já têm foto de Train (mesma sessão e classe)



256 × 256

Train, Val e Test: 12.256 / 2.626 / 2.627 imagens, todas do mesmo tamanho.

3 canais

todas RGB (JPEG); intervalo dos pixels 0–255 (uint8).

101 sessões

60 datas, de 2016 a 2018, com câmeras 0 a 4.

99,8%

das fotos de Val/Test têm foto de Train da mesma sessão e classe (mediana 15 s).

O QUE ISSO IMPLICA

- **Resize e padding: dispensados.** As imagens já são quadradas e iguais.
- **Espécie e sessão andam juntas** (Parkinsonia: 6 sessões): a CNN pode aprender o fundo, e não a planta.
- **Split por sessão: descartado.** Em 4 sementes, a Lantana ficou sem imagens no Test. Mantivemos o split por classe e declaramos o risco.

Padronização para a CNN: 224 × 224 × 3

Original 256 × 256	**Center crop 224 (Val/Test: escolhido)**	Resize 256 → 224 (alternativa)	Random crop + espelho (Train: augmentation)
			
Lantana	perde 23,4% da área	0% perdido, reamostra (×0,875)	posição sorteada a cada época
			
Rubber vine	perde 23,4% da área	0% perdido, reamostra (×0,875)	posição sorteada a cada época

Exemplos do Train (Lantana e Rubber vine). Contorno azul = o que Val/Test recebem.

1. **Resize:** não é necessário: todas já são 256 × 256
2. **Crop 224 × 224:** Train: posição aleatória + espelho (a planta não tem lado "certo"). Val/Test: centro.
3. **Normalização:** x / 255 → (x − μ) / σ por canal, com μ e σ do Train

→ entrada da CNN: 224 × 224 × 3 (float32)

POR QUE ESSA ESTRATÉGIA

- **Sem resize e sem padding:** imagens quadradas e iguais, sem distorção nem barras.
- **Crop sem reamostrar:** Train e Val/Test na mesma escala de pixel. Custo: 23,4% da área nas bordas em Val/Test (o crop aleatório expõe essas bordas no Train). Alternativa: resize 256 → 224, sem perda de área, mas reamostra.
- **224 px:** padrão de backbones pré-treinados e do artigo original.

NORMALIZAÇÃO ESCOLHIDA

Só do Train: μ = (0,376; 0,388; 0,377), σ = (0,234; 0,233; 0,231). Em Val/Test: |μ| ≤ 0,007 e σ entre 0,993 e 0,999. O μ é bem menor que o do ImageNet (fotos escuras): com backbone pré-treinado, usar as constantes do ImageNet.

ANÁLISE FINAL

O dataset está pronto para treinar uma CNN?

O DATASET ESTÁ BALANCEADO?

PARCIALMENTE

- **8 espécies:** sim (1.009–1.125; 1,11 : 1).
- **Com "Negative":** não (9.106 = 52,0% do total).
- **Tratamento:** pesos de classe (Negative ≈ 0,21; espécies ≈ 1,73–1,93), F1 macro e recall por classe.

TRAIN, VAL E TEST SÃO SEMELHANTES?

SIM

- Classes com a mesma proporção (χ^2 p ≈ 1,00) e mesma mistura de câmeras (p = 0,66).
- Médias RGB a ≤ 0,4 de 255; KS D ≤ 0,028; histogramas sobrepostos; pixels de 0 a 255.
- Semelhantes em boa parte porque o split é aleatório e divide as mesmas sessões entre os conjuntos.

AS IMAGENS ESTÃO PADRONIZADAS?

SIM

- Todas RGB e 256 × 256; entrada da CNN em 224 × 224 × 3 via crop, sem resize nem padding.
- Normalização com μ = (0,376, 0,388, 0,377) e σ = (0,234, 0,233, 0,231), só do Train.
- Após normalizar, Val/Test têm |μ| ≤ 0,007 e σ entre 0,993 e 0,999.

ESTÁ PRONTO PARA O TREINAMENTO?

SIM, COM 3 CUIDADOS

- Aplicar **pesos de classe** e acompanhar **F1 macro** e o recall de cada espécie.
- Usar o Test uma única vez. Ele divide sessões com o Train (99,8%), então a acurácia tende a ser otimista para locais novos.
- Analisar os erros por câmera/sessão: espécie e local estão associados (ex.: Parkinsonia, 6 sessões).