Classificar a espécie de planta em cada foto

Classificação

uma classe por imagem, entre 9: 8 espécies invasoras + “Negative”

224 × 224 × 3

entrada: foto de campo RGB (256 × 256 com crop), normalizada

9 probabilidades

saída softmax; a previsão é a classe mais provável

MÉTRICA PRINCIPAL: F1 MACRO

- “Negative” é **52%** das fotos: responder sempre “Negative” já daria 52% de accuracy.
- **F1 macro** = média do F1 das 9 classes, cada uma com o mesmo peso: uma espécie mal reconhecida derruba a nota.
- Também reportamos **accuracy, precision e recall** (macro e por classe) e a **matriz de confusão**.
- Não foram necessárias anotações extras: a base já traz um rótulo por imagem.



Uma foto de cada classe (Train). Contorno violeta = espécie-alvo; cinza = Negative.

PERGUNTA DA SPRINT 4

Quantos blocos convolucionais uma CNN treinada do zero precisa para reconhecer essas espécies?

Testamos **2, 3, 4 e 5 blocos**, mudando só a profundidade, com os mesmos dados, pré-processamento e protocolo de treino.

INTEGRANTES

Lucas Ferrari Lima · RM 563119
Carlos Eduardo Pires Cervelli · RM 563462
Felipe Krzyzanovski dos Santos Menezes · RM 564878
Leonardo Lopes Oliveira · RM 565437
Arthur de Souza Matos Dias · RM 566068
Guilherme Carreri Giampietro · RM 565676
Mateus Patrício Pereira · RM 564695

Mesmas imagens, mesma divisão, mesmo pré-processamento

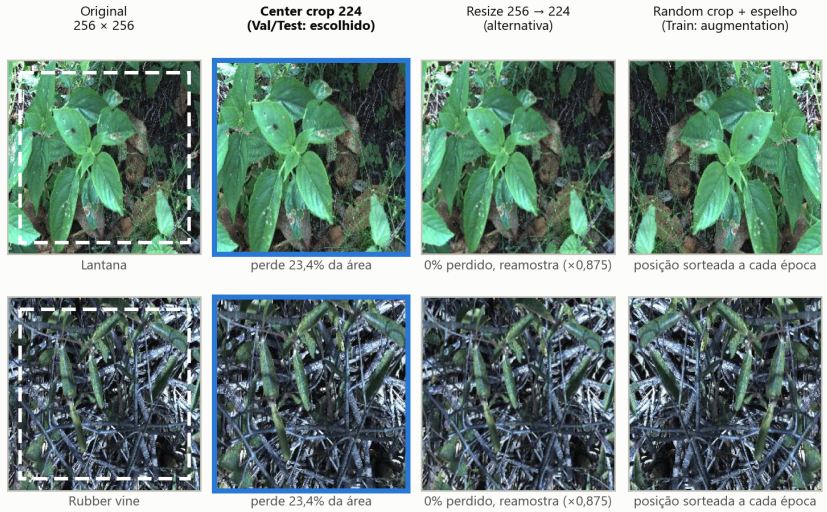
Train · 12.256 imagens · 70% | **Validation** 2.626 · 15% | **Test** 2.627 · 15%

CONJUNTO	IMAGENS	ESPÉCIES	NEGATIVE	PAPEL NESTA SPRINT
Train	12.256	5.882	6.374	ajusta os pesos de cada CNN
Validation	2.626	1.260	1.366	escolhe a época e a arquitetura
Test	2.627	1.261	1.366	nota final, lido uma única vez

CONTINUIDADE GARANTIDA

- A divisão **não foi refeita**: o split do **splits.csv** da Sprint 3 vai embutido no notebook.
- No Colab, o notebook confere os 17.509 nomes de arquivo (MD5) e as contagens antes de treinar.
- O Test só é carregado depois da escolha da arquitetura.

TAMANHO DE ENTRADA E PRÉ-PROCESSAMENTO (IGUAL NOS 4 MODELOS)

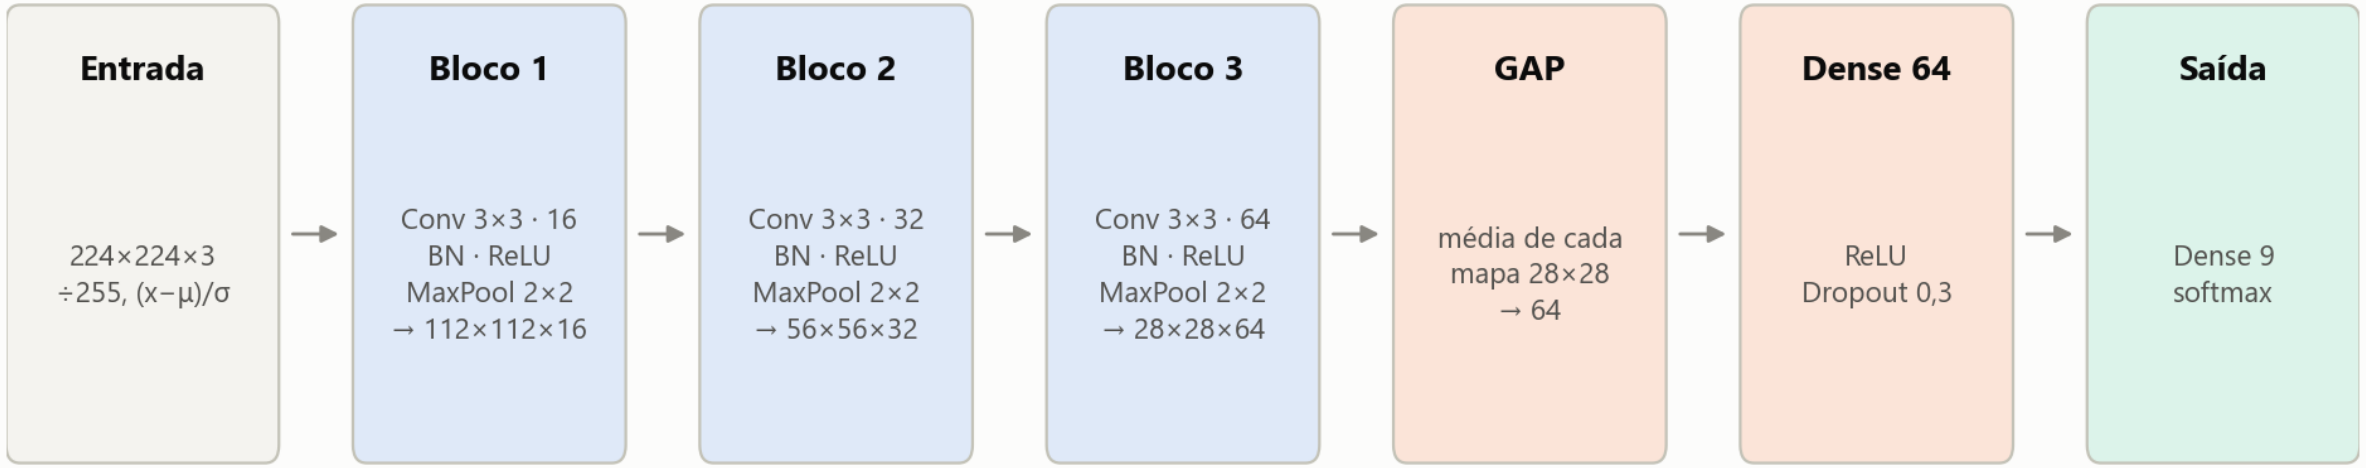


Exemplos do Train. Contorno azul = crop central usado em Val/Test.

1. **Crop 224 × 224, sem resize:** Train: posição aleatória + espelho horizontal. Val/Test: centro da foto 256 × 256.
2. **Normalização dentro do modelo:** ÷255 e (x − μ)/σ por canal, com μ e σ medidos só no Train na Sprint 3.
3. **Pesos de classe na loss:** $n / (k \cdot n_{classe})$, no Train: Negative ≈ 0,21; espécies ≈ 1,73 a 1,93.
4. **Mesmo protocolo:** Mesmos dados, augmentation, loss, otimizador, épocas e seed em todos os experimentos.

ARQUITETURA BASELINE

Ponto de partida: 3 blocos convolucionais, 28.665 parâmetros



MODEL.SUMMARY() RESUMIDO (KERAS)

CAMADA	SAÍDA	PARÂMETROS
Rescaling + Normalization	224 × 224 × 3	0
Bloco 1: Conv2D 16 + BN + ReLU + MaxPool	112 × 112 × 16	496
Bloco 2: Conv2D 32 + BN + ReLU + MaxPool	56 × 56 × 32	4.736
Bloco 3: Conv2D 64 + BN + ReLU + MaxPool	28 × 28 × 64	18.688
GlobalAveragePooling2D	64	0
Dense 64 (ReLU) + Dropout 0,3	64	4.160
Dense 9 (softmax)	9	585
Total (28.441 treináveis)		**28.665**

22 px

campo receptivo: cada ativação final "vê" 22 × 22 px da foto

GAP

média de cada mapa: 64 números, poucos parâmetros na cabeça

PROTOCOLO DE TREINO (FIXO NOS 4 MODELOS)

- Adam, lr 1e-3, reduzido à metade quando a loss de Val para de cair por 3 épocas.
- Batch 64, até 30 épocas; early stopping pelo F1 macro de Val (paciência 8).
- Guardamos os pesos da **época de maior F1 macro no Validation**.
- Entropia cruzada ponderada; seed 42; GPU T4 no Google Colab (mixed precision).
- Kernel 3×3, MaxPool 2×2, BatchNorm, GAP e Dense 64 iguais em todos os modelos.

Uma única mudança: o número de blocos convolucionais



POR QUE CADA MODELO FOI TESTADO

- **B2 (−1 bloco):** rede rasa basta? Campo receptivo de 10 px: só textura; esperávamos underfitting.
- **B3 (baseline):** ponto de partida simples, com 3 blocos.
- **B4 (+1 bloco):** campo receptivo de 46 px: ver folhas inteiras generaliza melhor?
- **B5 (+2 blocos):** até onde aprofundar? 411.129 parâmetros (14× a baseline): risco de overfitting.

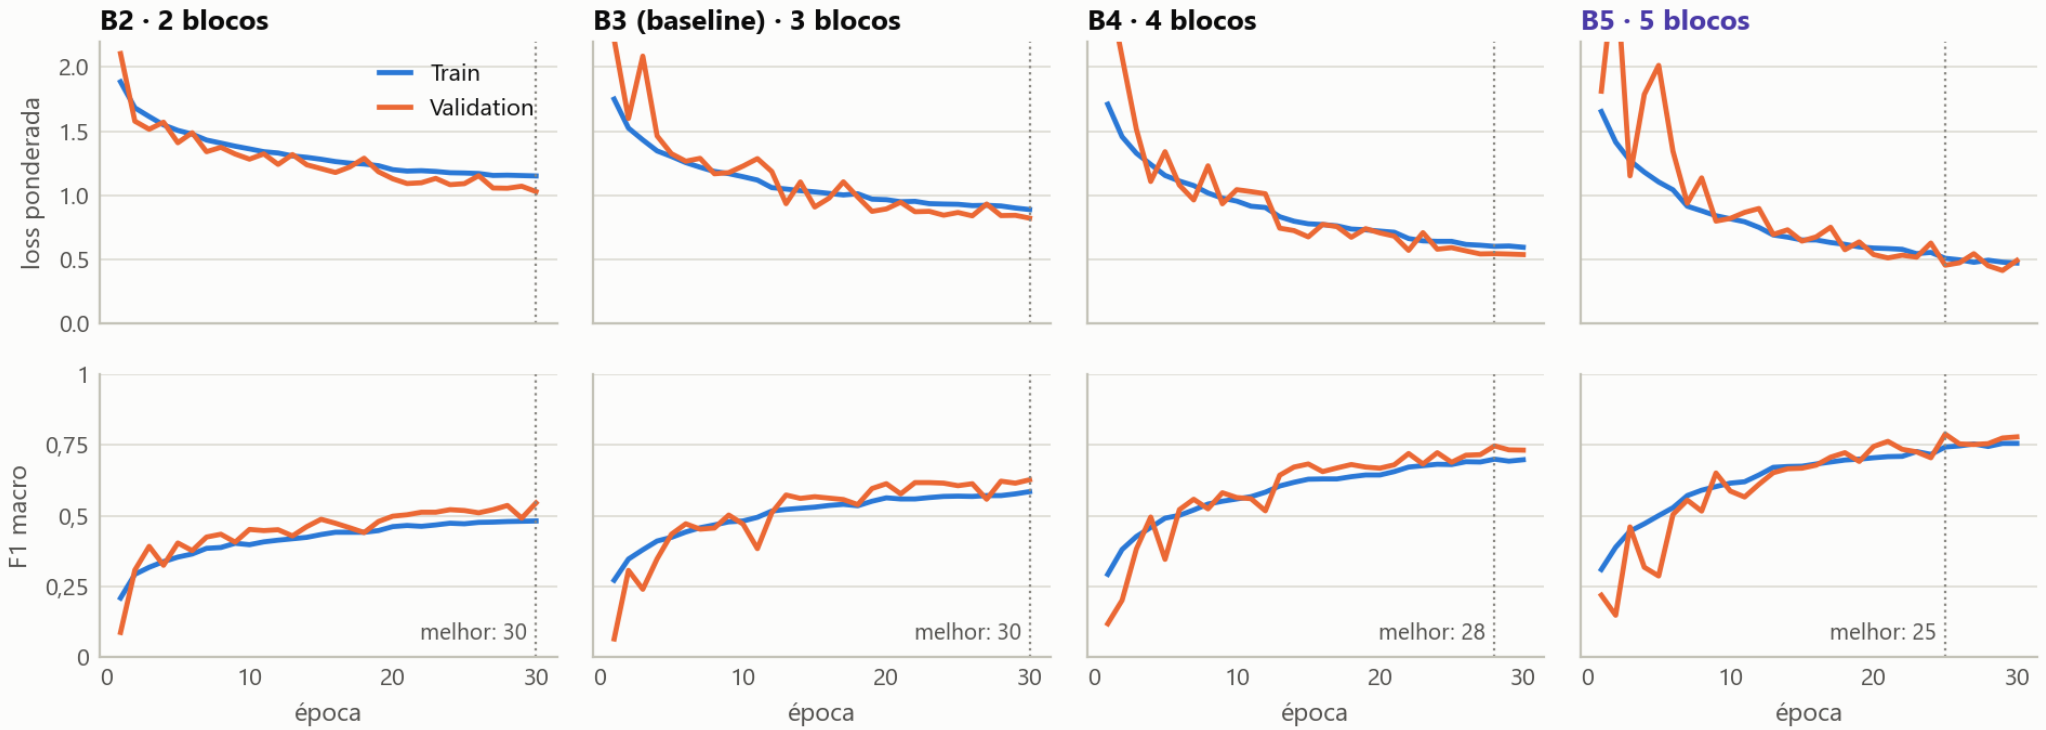
COMO MANTIVEMOS A COMPARAÇÃO CONTROLADA

- **Só muda a profundidade:** filtros começam em 16 e dobram a cada bloco; o bloco novo é a única diferença.
- Cada bloco a mais **dobra o campo receptivo** e **reduz o mapa final à metade**.
- Mesmo split, pré-processamento, loss, otimizador, épocas, seed e early stopping.
- **Regra de escolha fixada antes:** maior F1 macro no Val; empate (< 1 p.p.) → menos parâmetros.

COMPARAÇÃO NO VALIDATION

Cada bloco a mais melhorou o F1 macro, sem overfitting

EXPERIMENTO	MUDANÇA PRINCIPAL	PARÂMETROS	ACCURACY	F1 MACRO	ÉPOCA	OBSERVAÇÃO (CURVAS)
B2	−1 bloco (2 blocos)	7.929	57,6%	**54,5%**	30/30	Underfitting: F1 de Train só 0,48, ainda subindo na época 30
B3 (baseline)	Arquitetura inicial (3 blocos)	28.665	65,8%	**62,7%**	30/30	Ponto de partida; underfitting (F1 Train 0,58)
B4	+1 bloco (4 blocos)	107.001	78,0%	**74,7%**	28/30	+12,0 p.p. vs baseline; Val ≥ Train, sem overfitting
B5	+2 blocos (5 blocos)	411.129	82,1%	**78,9%**	25/30	+16,1 p.p. vs baseline; sem overfitting; Val oscila ±2 p.p.



LEITURA

- **Train abaixo do Val** porque é medido com augmentation e dropout ligados.
- **Nenhum sinal de overfitting:** as curvas de Val acompanham as de Train.
- **B2 e B3:** curvas baixas e ainda subindo, falta capacidade.
- Linha pontilhada = época cujos pesos foram guardados.

ARQUITETURA SELECIONADA

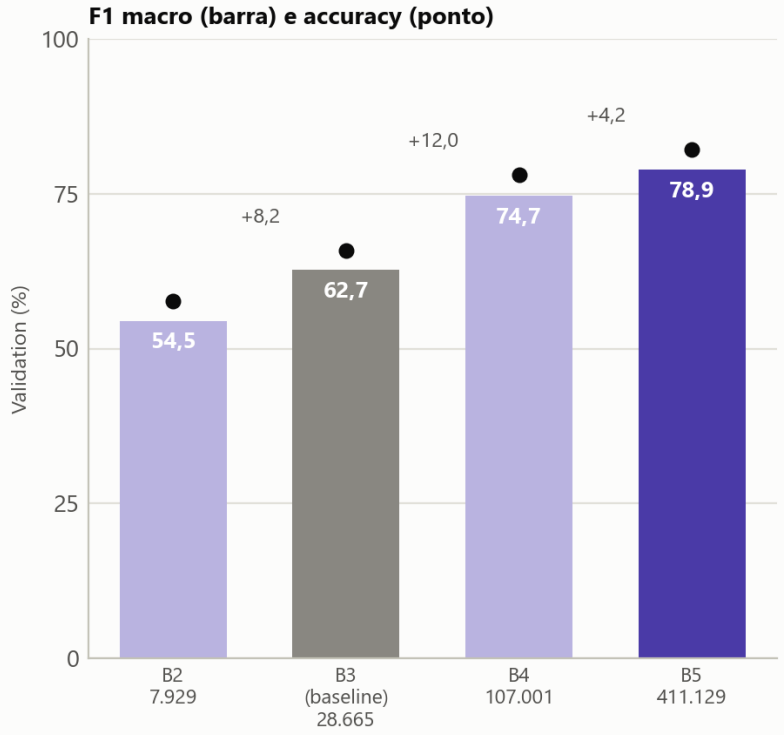
B5: 5 blocos, escolhido pelo Validation

78,9%
F1 macro no Validation (+16,1 p.p. sobre a baseline)

+4,2 p.p.
sobre o 2º melhor (B4): fora da margem de empate de 1 p.p.

76,3% × 72,8%
média das 5 últimas épocas (B5 × B4): não é um pico isolado

411.129
parâmetros (14× a baseline, ~1,6 MB): ainda uma rede pequena



F1 por classe no Validation (%)

	B2	B3	B4	B5
Chinee apple	39	51	65	**68**
Lantana	57	63	77	**79**
Parkinsonia	60	70	81	**80**
Parthenium	49	48	70	**78**
Prickly acacia	66	74	78	**82**
Rubber vine	51	66	78	**82**
Siam weed	60	71	79	**82**
Snake weed	45	50	60	**72**
Negative	64	72	83	**87**

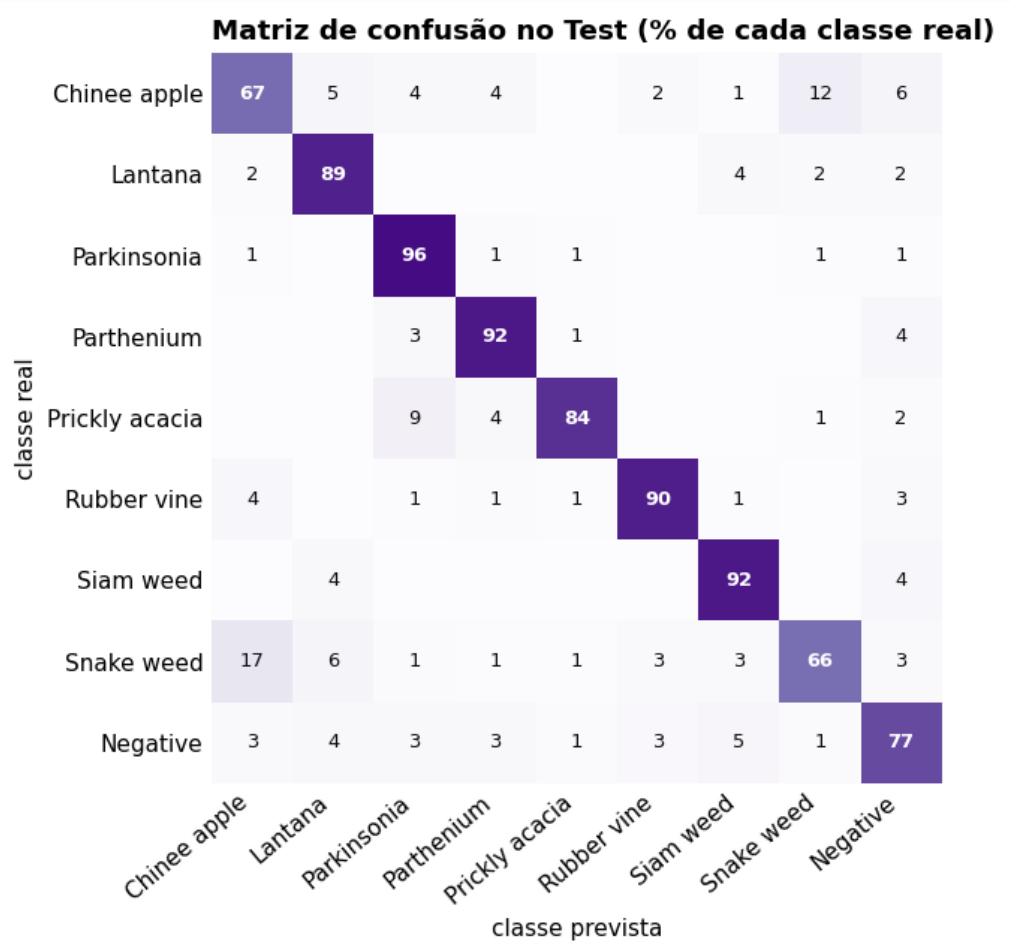
POR QUE B5

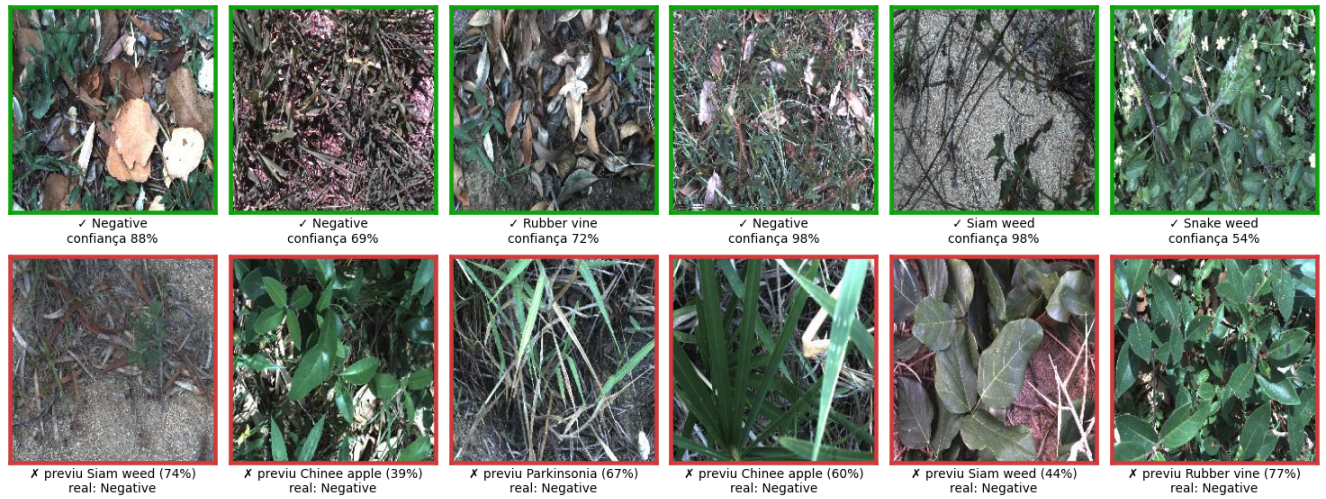
- **Maior F1 macro no Validation** (78,9%), que é a regra definida antes do treino.
- Melhora o F1 em **8 de 9 classes** sobre o B4; o maior ganho é em Snake weed (+12 p.p.).
- **Sem overfitting:** Val ≥ Train na melhor época.
- Campo receptivo de 94 px: cada ativação vê uma região maior da planta.
- **Classes mais equilibradas:** a pior classe sobe de 60% (B4) para 68% (B5).
- **Não foi escolhido por ser maior:** se B4 empatasse (< 1 p.p.), ficaria B4.

AVALIAÇÃO FINAL NO TEST (UMA ÚNICA VEZ)

B5 no Test: F1 macro 77,1%, accuracy 80,5%

80,5%	72,8%	83,8%	77,1%
accuracy (2.115 de 2.627 fotos)	precision macro	recall macro	F1 macro (−1,7 p.p. vs Validation)





O QUE OS ERROS MOSTRAM

- **Negative:** precision 96,4%, mas recall 76,8%. O modelo erra mais por falso alarme de espécie do que por deixar uma passar, o que é coerente com os pesos de classe na loss. Os 6 erros sorteados acima são todos desse tipo.
- **Maior confusão:** 17% das fotos de Snake weed foram previstas como Chinee apple.
- **Mais difícil:** Snake weed (recall 66,4%); ela e Chinee apple se confundem nos dois sentidos.
- **Confiança média:** 87,5% nos acertos × 62,3% nos erros: os erros vêm com menos certeza.

CONCLUSÃO

Profundidade foi decisiva; o ganho por bloco diminui

QUAL ALTERAÇÃO TEVE MAIOR IMPACTO?

DE 3 PARA 4 BLOCOS: +12,0 p.p.

- Passos de profundidade (F1 macro, Val): 2→3: **+8,2 p.p.** · 3→4: **+12,0 p.p.** · 4→5: **+4,2 p.p.**.
- O ganho cai no último passo (retorno decrescente), enquanto os parâmetros quase quadruplicam a cada bloco.
- Explicação provável: o campo receptivo passa de 22 para 46 px, então cada ativação vê uma região maior da planta, não só textura local.

ARQUITETURA FINAL

B5 · 5 BLOCOS · 411.129 PARÂMETROS

- Validation: F1 macro **78,9%**, accuracy 82,1%.
- Test (uma vez): F1 macro **77,1%**, accuracy 80,5%, recall 83,8%.
- Escolhida pelo F1 no Validation, não pelo tamanho; nenhuma das 4 redes mostrou overfitting em 30 épocas.

LIMITAÇÕES OBSERVADAS

4 PONTOS DE ATENÇÃO

- **Uma seed por modelo**, e o F1 de Val oscila ±2 p.p. entre épocas. Por isso usamos a regra de empate e conferimos a média das 5 últimas épocas.
- **Test otimista para locais novos:** 99,8% das fotos de Val/Test têm foto de Train da mesma sessão de captura (Sprint 3).
- **Falso alarme:** recall de Negative é 76,8%. A classe mais difícil é Snake weed (recall 66,4%).
- **Só a profundidade foi testada:** filtros, kernel, pooling e cabeça ficaram fixos.

O QUE TESTARÍAMOS NA PRÓXIMA ETAPA

PRÓXIMOS EXPERIMENTOS

- 6 blocos, ou 2 convoluções por bloco, para ver onde a profundidade satura.
- Sobre o B5: mais filtros (32 → 512) e kernel 5×5, uma mudança por vez.
- Mais épocas e 3 seeds por modelo (média ± desvio).
- Split por sessão de captura e transfer learning (MobileNet/ResNet) como teto.